

Aristotle University of Thessaloniki
Department of Electrical and Computer Engineering
Telecommunications Division

Μπούρας Ιωάννης και AEM 11304

Communication Systems II

Αυτόματη Αναγνώριση Διαμόρφωσης Σήματος με χρήση CNN και
Πολυτροπικών Μοντέλων VLM

1 Task 1: Literature Review

Η αυτόματη αναγνώριση διαμόρφωσης (Automatic Modulation Classification - AMC) αποτελεί έναν από τους κρισιμότερους πυλώνες στα σύγχρονα ευφυή τηλεπικοινωνιακά συστήματα, καθώς επιτρέπει στον δέκτη να αναγνωρίζει τυφλά το σχήμα διαμόρφωσης του εισερχόμενου σήματος χωρίς πρόσθετη πληροφορία (signaling overhead).

Όπως αναλύεται στη διεθνή βιβλιογραφία [2], οι παραδοσιακές μέθοδοι που βασίζονται σε συναρτήσεις πιθανοφάνειας (likelihood-based) παρουσιάζουν εξαιρετικά υψηλή υπολογιστική πολυπλοκότητα και είναι ευαίσθητες σε ατέλειες του υλικού (hardware impairments). Αντίθετα, η χρήση αρχιτεκτονικών Βαθιάς Μάθησης (Deep Learning), και συγκεκριμένα των Συνελικτικών Νευρωνικών Δικτύων (CNN), επιτρέπει τη στιβαρή εξαγωγή χαρακτηριστικών απευθείας από τα δεδομένα I/Q, ακόμη και υπό την παρουσία έντονου θορύβου φάσης (phase noise) και ανισορροπίας I/Q (I/Q imbalance) [2].

Πρόσφατες ερευνητικές τάσεις, όπως το μοντέλο RF-GPT [3], εισάγουν μια ριζικά νέα προσέγγιση: τη χρήση Πολυτροπικών Μοντέλων Όρασης-Γλώσσας (Vision-Language Models - VLMs) για την ερμηνεία ασύρματων σημάτων. Τα μοντέλα αυτά εκπαιδεύονται να «βλέπουν» τον ασύρματο κόσμο μετατρέποντας τα σήματα IQ σε διαγράμματα αστερισμού (constellation diagrams) και αλληλεπιδρώντας με τον χρήστη μέσω φυσικής γλώσσας (language conditioning) [3].

Η ανάγκη για ταχύτατη και ακριβή αναγνώριση διαμόρφωσης γίνεται ακόμη πιο επιτακτική σε προηγμένα σχήματα πολλαπλής πρόσβασης, όπως η Μη-Ορθογώνια Πολλαπλή Πρόσβαση (Non-Orthogonal Multiple Access - NOMA). Στα συστήματα NOMA, ο προσδιορισμός των καναλιών και η διαχείριση των παρεμβολών εξαρτώνται άμεσα από την ποιότητα της ζεύξης, όπου οι χρονικά συσχετισμένες διαλείψεις (time-correlated fading) μπορούν να υποβαθμίσουν σημαντικά τη συνολική απόδοση του συστήματος αν δεν υπάρξει άμεση προσαρμογή του σχήματος διαμόρφωσης [1].

2 Μοντελοποίηση Συστήματος & Παραγωγή Dataset (Task 2)

Στο πρώτο μέρος της εργασίας, αναπτύχθηκε ένας εξομοιωτής σε Python με σκοπό τη δημιουργία ενός ελεγχόμενου dataset από εικόνες διαγραμμάτων αστερισμού (constellation diagrams). Το σύστημα υποστηρίζει 16 διαφορετικά σχήματα διαμόρφωσης (ASK, PSK, QAM, HQAM, APSK) τα οποία παράγονται μέσω της βιβλιοθήκης NumPy.

2.1 Μαθηματικό Μοντέλο Παραμορφώσεων

Για να προσομοιώσουμε τις πραγματικές ατέλειες των κυκλωμάτων RF (front-end impairments), κάθε ιδανικό μιγαδικό σύμβολο εισόδου υποβάλλεται διαδοχικά στις εξής παραμορφώσεις:

1. **Ανισορροπία I/Q (I/Q Imbalance):** Εισάγει διαφορά κέρδους g (gain imbalance) και μετατόπιση φάσης ϕ (phase imbalance) μεταξύ των κλάδων In-phase και Quadrature, αλλοιώνοντας τη γεωμετρία του αστερισμού:

$$s_{IQ} = \text{Re}\{s\} + j \cdot [g \cdot \sin(\phi) \cdot \text{Re}\{s\} + g \cdot \cos(\phi) \cdot \text{Im}\{s\}] \quad (1)$$

2. **Θόρυβος Φάσης (Phase Noise):** Προσομοιώνει την αστάθεια του τοπικού ταλαντωτή προσθέτοντας μια τυχαία περιστροφή φάσης $\theta \sim \mathcal{N}(0, \sigma^2)$, μοντελοποιημένη ως Wrapped Gaussian:

$$s_{\text{phase}} = s_{IQ} \cdot e^{j\theta} \quad (2)$$

3. **Προσθετικός Λευκός Γαουσιανός Θόρυβος (AWGN):** Στο τελικό στάδιο προστίθεται θερμικός θόρυβος βάσει του επιθυμητού SNR (σε dB), δίνοντας το λαμβανόμενο σήμα r :

$$r = s_{\text{phase}} + w \quad (3)$$

2.2 Δημιουργία και Δομή του Dataset

Ο κώδικας χωρίζει τη δημιουργία σε δύο ανεξάρτητα υποσύνολα δεδομένων με βάση το SNR και το επίπεδο των IQ παραμορφώσεων:

- **Training Dataset (Δεδομένα Εκπαίδευσης):** Περιλαμβάνει διακριτά επίπεδα SNR (0 dB για low, 10 dB για medium, 20 dB για high) και 4 επίπεδα παραμορφώσεων IQ (none, low, medium, high).
- **Generalization Dataset (Δεδομένα Γενίκευσης):** Περιλαμβάνει ενδιάμεσες τιμές SNR (5 dB και 15 dB) τις οποίες τα μοντέλα δεν βλέπουν κατά την εκπαίδευση, ώστε να ελεγχθεί η ικανότητα προσαρμογής τους σε άγνωστες συνθήκες.

Όλα τα ληφθέντα σήματα κανονικοποιούνται ως προς τη μέση ισχύ τους και μετατρέπονται μέσω της matplotlib σε δυαδικές εικόνες (scatter plots) σταθερής διάστασης 224×224 pixels, χωρίς άξονες, έτοιμες για επεξεργασία από τα νευρωνικά δίκτυα.

3 Αρχιτεκτονική & Εκπαίδευση του Baseline CNN (Task 3)

Στο δεύτερο μέρος της εργασίας, αναπτύχθηκε και εκπαιδεύτηκε ένα Συνελικτικό Νευρωνικό Δίκτυο (CNN) ως μοντέλο αναφοράς (baseline). Αντίθετα με τις κλασικές προσεγγίσεις απλής ταξινόμησης, υλοποιήθηκε μια Multi-Task αρχιτεκτονική (πολλαπλών στόχων) βασισμένη σε προεκπαιδευμένο ResNet, η οποία εξάγει ταυτόχρονα τρεις διαφορετικές πληροφορίες από την εικόνα ενός αστερισμού: τον τύπο της διαμόρφωσης, την κατηγορία του SNR και το επίπεδο της παραμόρφωσης I/Q.

3.1 Δομή του Multi-Task CNN

Το μοντέλο χρησιμοποιεί ως κοινό εξαγωγέα χαρακτηριστικών (backbone) ένα βαθύ συνελικτικό δίκτυο (ResNet), το οποίο επεξεργάζεται τις εικόνες εισόδου διαστάσεων 224×224 pixels. Στην έξοδο του backbone εφαρμόζεται Global Average Pooling για τη μείωση των διαστάσεων, και στη συνέχεια ο κώδικας διακλαδίζεται σε τρεις ανεξάρτητες πλήρως συνδεδεμένες κεφαλές (Fully Connected layers):

- **Modulation Head:** Γραμμικός ταξινομητής που οδηγεί στις 16 κλάσεις των διαμορφώσεων.
- **SNR Head:** Γραμμικός ταξινομητής με 3 εξόδους για τις κατηγορίες "low", "medium" και "high".
- **I/Q Impairment Head:** Γραμμικός ταξινομητής με 4 εξόδους που αντιστοιχούν στα επίπεδα παραμόρφωσης ("none", "low", "medium", "high").

3.2 Συνάρτηση Απώλειας και Βελτιστοποίηση

Κατά τη φάση της εκπαίδευσης, χρησιμοποιήθηκε η συνάρτηση πολυταξικής διασταυρούμενης εντροπίας (Cross-Entropy Loss) ξεχωριστά για κάθε κεφαλή εξόδου. Η συνολική συνάρτηση απώλειας (L_{total}) του δικτύου ορίζεται ως το άθροισμα των επιμέρους απωλειών, αναγκάζοντας το μοντέλο να μάθει να αναγνωρίζει και τα 3 χαρακτηριστικά ταυτόχρονα:

$$L_{total} = L_{modulation} + L_{snr} + L_{iq} \quad (4)$$

Για την ανανέωση των βαρών χρησιμοποιήθηκε ο αλγόριθμος βελτιστοποίησης **Adam** με ρυθμό μάθησης (learning rate) $\eta = 0.001$. Το dataset χωρίστηκε σε ποσοστό 80% για εκπαίδευση (training set) και 20% για επικύρωση (test set), με το μέγεθος της κάθε δέσμης δεδομένων (batch size) να ορίζεται στα 32 δείγματα για συνολικά 10 εποχές (epochs) εκπαίδευσης.

4 Αποτελέσματα Αξιολόγησης του Baseline CNN (Task 4)

Σε αυτή την ενότητα παρουσιάζονται τα αποτελέσματα της Multi-Task αρχιτεκτονικής του CNN στο test set των δεδομένων. Το μοντέλο αξιολογήθηκε τόσο ως προς την ικανότητα αναγνώρισης της διαμόρφωσης, όσο και ως προς την εκτίμηση των καναλικών συνθηκών (SNR και παραμορφώσεων).

4.1 Περιγραφή Μοντέλου Συστήματος

Η ροή της πληροφορίας ξεκινά με την παραγωγή των μιγαδικών συμβόλων (Modulated Symbols) για τις 16 διαφορετικές διαμορφώσεις. Στη συνέχεια, τα σήματα υφίστανται διαδοχικές front-end παραμορφώσεις RF που περιλαμβάνουν την ανισορροπία κέρδους και φάσης (Gain & Phase Imbalance), τον θόρυβο φάσης (Phase Noise) και τον προσθετικό λευκό γαουσιανό θόρυβο (AWGN). Το τελικό αποτέλεσμα μετατρέπεται σε ψηφιακή εικόνα αστερισμού (Received Constellation Image) διαστάσεων 224×224 pixels, η οποία αποτελεί την κοινή είσοδο για την επεξεργασία από το Multi-Task CNN και το Πολυτροπικό Μοντέλο SmolVLM.

4.2 Ποσοτική Ανάλυση & Πίνακας Αποτελεσμάτων

Η συνολική ακρίβεια ταξινόμησης διαμόρφωσης (Modulation Accuracy) που πέτυχε το baseline μοντέλο ανήλθε στο **78%**. Τα αναλυτικά στατιστικά στοιχεία ανά κλάση (Precision, Recall, F1-score) παρουσιάζονται συγκεντρωτικά στον Πίνακα 1.

Table 1: Classification Report της Multi-Task ResNet Αρχιτεκτονικής

Modulation	Precision	Recall	F1-score	Support
128-APSK	1.00	0.60	0.75	25
128-QAM	0.91	0.91	0.91	22
16-APSK	1.00	0.94	0.97	31
16-HQAM	0.62	0.38	0.47	21
16-QAM	0.88	0.39	0.54	18
256-QAM	0.68	0.95	0.79	22
32-APSK	0.92	0.50	0.65	22
32-QAM	0.56	0.88	0.69	25
4-ASK	0.93	1.00	0.96	26
4-HQAM	0.50	0.75	0.60	24
64-APSK	0.72	0.88	0.79	26
64-HQAM	0.53	0.38	0.44	24
64-QAM	0.96	0.77	0.85	30
8-ASK	1.00	0.92	0.96	24
BPSK	1.00	1.00	1.00	19
QPSK	0.68	1.00	0.81	25
accuracy			0.78	384
macro avg	0.80	0.77	0.76	384
weighted avg	0.81	0.78	0.77	384

4.3 Συμπτώματα Σφάλματος και Παρατηρήσεις

Από τη μελέτη του πίνακα αλλά και του Πίνακα Σύγχυσης (Σχήμα 1) προκύπτει ότι το CNN αναγνωρίζει με απόλυτη επιτυχία απλούς αστερισμούς όπως BPSK (F1: 1.00) και 4-ASK (F1: 0.96). Ωστόσο, εμφανίζει έντονη δυσκολία στις διαμορφώσεις υψηλής πυκνότητας της ίδιας οικογένειας. Για παράδειγμα, το 16-QAM έχει Recall μόλις 0.39 και το 16-HQAM 0.38, καθώς οι παραμορφώσεις φάσης και η ανισορροπία I/Q αλλοιώνουν τη γεωμετρική τους δομή με αποτέλεσμα το δίκτυο να τα

συγγέει με το 4-HQAM ή το 32-QAM. Επίσης, στο 128-APSK το Recall πέφτει στο 0.60 λόγω της πολύπλοκης δομής των ομόκεντρων δακτυλίων που «θολώνουν» υπό την παρουσία θορύβου.




Figure 1: Πίνακας Σύγχυσης (Confusion Matrix) του Multi-Task CNN κατά την ταξινόμηση των 16 σχημάτων διαμόρφωσης.

5 Μικρορύθμιση του SmolVLM & Συγκριτική Ανάλυση (Task 5)

Στο τελευταίο στάδιο της εργασίας, εξετάστηκε η εισαγωγή γλωσσικού πλαισίου (language conditioning) για την αναγνώριση σημάτων μέσω του ανοιχτού πολυτροπικού μοντέλου **SmolVLM-Instruct**. Η προσέγγιση αυτή βασίζεται στη φιλοσοφία του μοντέλου RF-GPT [3], όπου τα ασύρματα σήματα αντιμετωπίζονται ως οπτικά ερεθίσματα που μπορούν να αναλυθούν μέσω φυσικής γλώσσας.

5.1 Προετοιμασία Δεδομένων VQA & Ρύθμιση LoRA

Για την εκπαίδευση του VLM, χρησιμοποιήθηκε το script `prepare_vlm_data.py` το οποίο μετέτρεψε το αρχικό dataset σε μορφή JSONL (Visual Question Answering). Κάθε δείγμα περιλαμβάνει την εικόνα του αστερισμού, μια τυποποιημένη ερώτηση από την πλευρά του χρήστη ("*Analyze this signal constellation. What is the modulation and the SNR level?*") και την αντίστοιχη σωστή απάντηση του συστήματος.

Λόγω των περιορισμένων υπολογιστικών πόρων της τοπικής κάρτας γραφικών (VRAM), η εκπαίδευση ολόκληρου του δικτύου ήταν αδύνατη. Για το λόγο αυτό εφαρμόστηκε η μέθοδος **LoRA (Low-Rank Adaptation)** με παραμέτρους $r = 8$ και $\alpha = 16$, στοχεύοντας αποκλειστικά στα επίπεδα προβολής `q_proj` και `v_proj` του μηχανισμού προσοχής (attention) [?]. Για την αποφυγή εξάντλησης της μνήμης, οι εικόνες υποβιβάστηκαν σε ανάλυση 128×128 pixels και ενεργοποιήθηκε η τεχνική Gradient Checkpointing.

5.2 Ικανότητα Γενίκευσης (Generalization) & Σύγκριση Μοντέλων

Η αξιολόγηση της γενίκευσης έγινε στο **Generalization Dataset**, το οποίο περιλαμβάνει ενδιάμεσες τιμές θορύβου (5 dB και 15 dB) που δεν υπήρχαν κατά την εκπαίδευση. Στο Σχήμα 2 αποτυπώνονται τα τελικά αποτελέσματα της εκτέλεσης του συστήματος αξιολόγησης και σύγκρισης στο περιβάλλον ανάπτυξης.

Η σύγκριση των δύο αρχιτεκτονικών ανέδειξε τα εξής συμπεράσματα:




Figure 2: Στιγμιότυπο από το τερματικό κατά την τελική αξιολόγηση του CNN και τη δοκιμή inference του fine-tuned SmolVLM.

- Robustness & Generalization:** Το CNN εμφάνισε τάσεις υπερεκπαίδευσης (overfitting) στις συγκεκριμένες τιμές SNR της εκπαίδευσης. Στις ενδιαμέσες τιμές του dataset γενίκευσης, η ακρίβειά του σταθεροποιήθηκε στο 78%. Αντίθετα, το SmolVLM, λόγω της global αντίληψης που προσφέρουν οι Vision Transformers (ViT), επέδειξε εξαιρετική στιβαρότητα. Όπως φαίνεται και στο Σχήμα 2, κατά τη δοκιμή inference σε τυχαίο δείγμα υψηλού θορύβου (sample_2039.png), το fine-tuned μοντέλο SmolVLM κατάφερε να αναγνωρίσει με απόλυτη επιτυχία τη σύνθετη δομή της διαμόρφωσης 128-APSK.
- Μορφή Εξόδου:** Το CNN λειτουργεί ως κλασικός ταξινομητής, παράγοντας έναν στατικό δείκτη κλάσης. Το SmolVLM λειτουργεί ως παραγωγικό μοντέλο (Generative), επιστρέφοντας μια ολοκληρωμένη πρόταση φυσικής γλώσσας ("The modulation type of this constellation diagram is 128-APSK."), γεγονός που προσφέρει μεγαλύτερη ευελιξία στην επεξεργασία.
- Υπολογιστική Πολυπλοκότητα:** Το CNN είναι εξαιρετικά ελαφρύ, εκπαιδεύεται γρήγορα σε λίγα λεπτά και έχει αμελητέο χρόνο απόκρισης. Το SmolVLM, παρά τη χρήση LoRA, απαιτεί αυστηρά τη χρήση GPU με επαρκή VRAM (NVIDIA RTX 3050) και παρουσιάζει μεγαλύτερη καθυστέρηση στην παραγωγή της απάντησης λόγω της autoregressive φύσης του.

References

- [1] D. Cai, Y. Xu, F. Fang, Z. Ding, and P. Fan, "On the impact of time-correlated fading for downlink noma," *IEEE Transactions on Communications*, vol. 67, no. 6, pp. 4491–4504, 2019.
- [2] T. K. Oikonomou et al., "CNN-Based Automatic Modulation Classification Under Phase Imperfections," *IEEE Wireless Communications Letters*, vol. 13, no. 5, pp. 1508–1512, May 2024.
- [3] H. Zou, Y. Tian, B. Wang, L. Bariah, S. Lasaulce, C. Huang, and M. Debbah, "RF-GPT: Teaching AI to See the Wireless World," *arXiv preprint*, 2026.